

PCA

May 13, 2026

1 Análisis de Componentes Principales (PCA)

Este notebook muestra como calcular las componentes principales del archivo `europe.csv` e interpretar la **primera componente principal (PC1)** de forma gráfica y teórica.

```
[1]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pathlib import Path

from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

plt.rcParams["figure.figsize"] = (10, 6)
plt.rcParams["axes.grid"] = True
```

1.1 1. Carga de datos

El notebook busca `europe.csv` en una carpeta `data/`.

```
[2]: csv_path = Path("data/europe.csv")

print(f"Archivo cargado desde: {csv_path}")

df = pd.read_csv(csv_path)
df.head()
```

Archivo cargado desde: data\europa.csv

```
[2]:
```

	Country	Area	GDP	Inflation	Life.expect	Military	\
0	Austria	83871	41600	3.5	79.91	0.80	
1	Belgium	30528	37800	3.5	79.65	1.30	
2	Bulgaria	110879	13800	4.2	73.84	2.60	
3	Croatia	56594	18000	2.3	75.99	2.39	
4	Czech Republic	78867	27100	1.9	77.38	1.15	

	Pop.growth	Unemployment
0	0.03	4.2
1	0.06	7.2

2	-0.80	9.6
3	-0.09	17.7
4	-0.13	8.5

```
[3]: df.describe().T.round(2)
```

```
[3]:
```

	count	mean	std	min	25%	50% \
Area	28.0	166422.54	165538.68	2586.00	48083.25	87980.50
GDP	28.0	31860.71	14502.12	7200.00	20350.00	30500.00
Inflation	28.0	3.34	1.40	0.20	2.58	3.35
Life.expect	28.0	78.12	3.19	68.74	76.02	79.53
Military	28.0	1.61	0.80	0.00	1.10	1.50
Pop.growth	28.0	0.12	0.50	-0.80	-0.18	0.06
Unemployment	28.0	9.92	4.68	2.80	6.92	8.45

	75%	max
Area	304176.25	603550.00
GDP	38750.00	80600.00
Inflation	4.03	8.00
Life.expect	80.32	81.86
Military	1.92	4.30
Pop.growth	0.40	1.14
Unemployment	12.72	21.70

1.2 2. Preprocesamiento: selección de variables y estandarización

PCA es sensible a la escala de las variables. Por ejemplo, **Area** puede tomar valores de cientos de miles, mientras que **Inflation** o **Pop.growth** son porcentajes. Si no se estandarizan los datos, las variables con mayor magnitud numérica dominarían artificialmente las componentes.

Por eso se aplica **StandardScaler**, que transforma cada variable para que tenga media 0 y desvío estándar 1.

```
[4]: features = [col for col in df.columns if col != "Country"]
X = df[features]
countries = df["Country"]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

X_scaled_df = pd.DataFrame(X_scaled, columns=features, index=countries)
X_scaled_df.head().round(2)
```

```
[4]:
```

	Area	GDP	Inflation	Life.expect	Military	Pop.growth \
Country						
Austria	-0.51	0.68	0.11	0.57	-1.02	-0.18
Belgium	-0.84	0.42	0.11	0.49	-0.39	-0.12
Bulgaria	-0.34	-1.27	0.62	-1.37	1.26	-1.86

Croatia	-0.68	-0.97	-0.76	-0.68	1.00	-0.42
Czech Republic	-0.54	-0.33	-1.05	-0.24	-0.58	-0.50

	Unemployment
Country	
Austria	-1.25
Belgium	-0.59
Bulgaria	-0.07
Croatia	1.69
Czech Republic	-0.31

1.3 3. Cálculo de PCA con scikit-learn

Se calculan todas las componentes principales.

```
[5]: pca = PCA()
scores = pca.fit_transform(X_scaled)

component_names = [f"PC{i+1}" for i in range(len(features))]

# Coeficientes de los vectores propios: cuánto pesa cada variable en cada PC.
coefficients = pd.DataFrame(
    pca.components_.T,
    columns=component_names,
    index=features,
)

scores_df = pd.DataFrame(scores, columns=component_names)
scores_df.insert(0, "Country", countries)

explained_variance = pd.DataFrame({
    "Componente": component_names,
    "Varianza explicada": pca.explained_variance_ratio_,
    "Varianza acumulada": np.cumsum(pca.explained_variance_ratio_),
})

explained_variance.round(4)
```

```
[5]:
```

	Componente	Varianza explicada	Varianza acumulada
0	PC1	0.4610	0.4610
1	PC2	0.1696	0.6306
2	PC3	0.1519	0.7825
3	PC4	0.1101	0.8925
4	PC5	0.0654	0.9580
5	PC6	0.0241	0.9821
6	PC7	0.0179	1.0000

```
[6]: pc1_pct = explained_variance.loc[0, "Varianza explicada"] * 100
      pc2_pct = explained_variance.loc[1, "Varianza explicada"] * 100

      print(f"PC1 explica {pc1_pct:.2f}% de la varianza total.")
      print(f"PC2 explica {pc2_pct:.2f}% de la varianza total.")
      print(f"PC1 + PC2 explican {(pc1_pct + pc2_pct):.2f}% de la varianza total.")
```


PC1 explica 46.10% de la varianza total.
 PC2 explica 16.96% de la varianza total.
 PC1 + PC2 explican 63.06% de la varianza total.

1.3.1 Varianza explicada


La primera componente principal resume una parte importante de la información del dataset. En este caso, **PC1 explica aproximadamente el 46% de la varianza total** de las variables estandarizadas.

Esto no significa que PC1 explique “todo” el comportamiento de los países, sino que captura la dirección de mayor variabilidad conjunta entre las variables económicas, sociales y geográficas.

```
[7]: plt.figure(figsize=(9, 5))
      plt.plot(
          explained_variance["Componente"],
          explained_variance["Varianza explicada"] * 100,
          marker="o",
      )
      plt.title("Varianza explicada por componente principal")
      plt.xlabel("Componente principal")
      plt.ylabel("Varianza explicada (%)")
      plt.show()
```



```
[8]: plt.figure(figsize=(9, 5))
plt.plot(
    explained_variance["Componente"],
    explained_variance["Varianza acumulada"] * 100,
    marker="o",
)
plt.title("Varianza explicada acumulada")
plt.xlabel("Cantidad de componentes")
plt.ylabel("Varianza acumulada (%)")
plt.ylim(0, 105)
plt.show()
```



1.4 4. Interpretación de PC1

Para interpretar PC1 conviene distinguir dos conceptos relacionados pero no idénticos:

1. **Coefficientes de la componente:** son los pesos del vector propio de PC1. Indican cómo se combina cada variable estandarizada para construir la componente.
2. **Correlaciones variable-PC1:** miden la correlación entre cada variable original estandarizada y los scores de PC1.

La interpretación cualitativa suele mirar signos y magnitudes. Variables con signo positivo se mueven en la dirección positiva de PC1, mientras que variables con signo negativo se mueven en dirección opuesta.

```
[9]: pc1_table = pd.DataFrame({
    "Coeficiente en PC1": coefficients["PC1"],
})

# Correlaciones entre las variables estandarizadas y los scores de PC1.
pc1_table["Correlación con PC1"] = [
    np.corrcoef(X_scaled_df[var], scores_df["PC1"])[0, 1]
    for var in features
]

pc1_table["Magnitud abs. coeficiente"] = pc1_table["Coeficiente en PC1"].abs()
pc1_table = pc1_table.sort_values("Magnitud abs. coeficiente", ascending=False)
pc1_table.round(4)
```


```
[9]:
```

	Coeficiente en PC1	Correlación con PC1 \
GDP	0.5005	0.8991
Life.expect	0.4829	0.8674
Pop.growth	0.4757	0.8546
Inflation	-0.4065	-0.7303
Unemployment	-0.2717	-0.4880
Military	-0.1881	-0.3379
Area	-0.1249	-0.2243

	Magnitud abs. coeficiente
GDP	0.5005
Life.expect	0.4829
Pop.growth	0.4757
Inflation	0.4065
Unemployment	0.2717
Military	0.1881
Area	0.1249

```
[10]: pc1_coefficients = coefficients["PC1"].sort_values()

plt.figure(figsize=(9, 5))
plt.barh(pc1_coefficients.index, pc1_coefficients.values)
plt.axvline(0, linewidth=1)
plt.title("Coeficientes de las variables en PC1")
plt.xlabel("Coeficiente")
plt.ylabel("Variable")
plt.show()
```



1.4.1 Interpretación teórica de PC1

PC1 tiene pesos positivos fuertes en:

- GDP: mayor riqueza económica.
- Life.expect: mayor expectativa de vida, asociada a mejores condiciones de bienestar y salud.
- Pop.growth: crecimiento poblacional, que en este contexto puede asociarse a dinámicas demográficas más favorables o a atracción migratoria.

Y pesos negativos relevantes en:

- Inflation: mayor inflación.
- Unemployment: mayor desempleo.
- Military: menor contribución relativa, pero con signo negativo en PC1.

Por lo tanto, **PC1 puede interpretarse como un eje de desarrollo y estabilidad socioeconómica.**

- Valores altos de PC1: países con mayor GDP, mayor expectativa de vida y mejores indicadores generales.
- Valores bajos de PC1: países con mayor inflación, mayor desempleo y menor desarrollo relativo dentro del conjunto analizado.

1.5 5. Países extremos según PC1

Para validar la interpretación, observamos qué países tienen los scores más altos y más bajos en PC1.

```
[11]: pc_scores_ordered = scores_df[["Country", "PC1", "PC2"]].sort_values("PC1",
    ↪ascending=False).round(4)

print("Países con PC1 más alta:")
display(pc_scores_ordered.head(8))

print("Países con PC1 más baja:")
display(pc_scores_ordered.tail(8).sort_values("PC1"))
```

Países con PC1 más alta:

	Country	PC1	PC2
16	Luxembourg	3.4784	-1.0763
25	Switzerland	3.2816	-0.1082
18	Norway	2.1065	-0.1440
17	Netherlands	1.8401	-0.0572
12	Ireland	1.8089	0.5218
11	Iceland	1.5837	-1.4773
0	Austria	1.0817	-1.2701
5	Denmark	0.9552	-0.4096

Países con PC1 más baja:

	Country	PC1	PC2
26	Ukraine	-4.5803	-2.8290

2	Bulgaria	-2.6099	0.2696
6	Estonia	-2.4877	-0.0858
14	Latvia	-2.3061	-0.6753
15	Lithuania	-1.5301	-0.1950
19	Poland	-1.4718	0.0730
10	Hungary	-1.3969	-0.0342
3	Croatia	-1.2701	1.9014

Los países con PC1 más alta aparecen asociados al polo de mayor desarrollo socioeconómico relativo. En este dataset suelen ubicarse allí países como **Luxemburgo, Suiza, Noruega, Países Bajos** o **Irlanda**.

En el extremo negativo aparecen países como **Ucrania, Bulgaria, Estonia, Letonia** o **Lituania**, que en estos datos presentan peores valores relativos en las variables que más empujan PC1 hacia el lado negativo.


1.6 6. Visualización gráfica de PC1 y PC2

Primero se grafican los países proyectados sobre PC1 y PC2. Luego se construye un biplot que agrega flechas para las variables originales.

```
[12]: plt.figure(figsize=(12, 8))
plt.scatter(scores_df["PC1"], scores_df["PC2"], s=70)

for _, row in scores_df.iterrows():
    plt.annotate(
        row["Country"],
        (row["PC1"], row["PC2"]),
        xytext=(5, 4),
        textcoords="offset points",
        fontsize=9,
    )

plt.axhline(0, linewidth=1)
plt.axvline(0, linewidth=1)
plt.title("Países proyectados en el plano PC1-PC2")
plt.xlabel(f"PC1 ({pc1_pct:.2f}% de varianza) - desarrollo / estabilidad_↪socioeconómica")
plt.ylabel(f"PC2 ({pc2_pct:.2f}% de varianza)")
plt.show()
```



```
[13]: def plot_biplot(scores_df, coefficients, features, pc1_pct, pc2_pct):
    # Biplot simple para PC1 y PC2.
    x = scores_df["PC1"].to_numpy()
    y = scores_df["PC2"].to_numpy()

    # Escalado de scores para que entren visualmente con las flechas.
    x_scaled = x / np.max(np.abs(x))
    y_scaled = y / np.max(np.abs(y))

    plt.figure(figsize=(13, 9))
    plt.scatter(x_scaled, y_scaled, s=70, alpha=0.8)

    for i, country in enumerate(scores_df["Country"]):
        plt.annotate(country, (x_scaled[i], y_scaled[i]), xytext=(5, 4),
        ↪textcoords="offset points", fontsize=9)

    # Flechas de variables: se usan los coeficientes de PC1 y PC2.
    for var in features:
        x_arrow = coefficients.loc[var, "PC1"]
        y_arrow = coefficients.loc[var, "PC2"]
        plt.arrow(0, 0, x_arrow, y_arrow, head_width=0.03,
        ↪length_includes_head=True)
```


```

plt.text(x_arrow * 1.12, y_arrow * 1.12, var, ha="center", va="center",
        ↪fontsize=11, fontweight="bold")

plt.axhline(0, linewidth=1)
plt.axvline(0, linewidth=1)
plt.title("Biplot PCA: países y variables")
plt.xlabel(f"PC1 ({pc1_pct:.2f}%) - desarrollo / estabilidad_↪
        ↪socioeconómica")
plt.ylabel(f"PC2 ({pc2_pct:.2f}%)")
plt.xlim(-1.2, 1.2)
plt.ylim(-1.2, 1.2)
plt.show()

plot_biplot(scores_df, coefficients, features, pc1_pct, pc2_pct)

```



1.6.1 Lectura del biplot

En el biplot, las flechas de GDP, Life.expect y Pop.growth apuntan hacia el lado positivo de PC1. Esto confirma gráficamente que el eje horizontal puede leerse como un eje de mayor desarrollo y estabilidad socioeconómica.

En sentido contrario se ubican Inflation y Unemployment, que empujan hacia el lado negativo de

PC1. Por eso, los países ubicados a la izquierda del gráfico tienden a presentar peores condiciones relativas en esos indicadores.

La PC2 explica menos varianza que PC1 y su interpretación es menos clara. En estos datos, PC2 tiene contribuciones importantes de **Military** y **Unemployment**, por lo que no conviene sobreinterpretarla como “tamaño geográfico” o “poder geopolítico”. El análisis central de la consigna debe enfocarse en PC1.

1.7 7. Conclusión

Luego de estandarizar las variables y aplicar PCA con `scikit-learn`, se observa que la primera componente principal explica aproximadamente el **46% de la varianza total** de las variables estandarizadas.

Al analizar los coeficientes de PC1, las variables con mayor peso positivo son **GDP**, **Life.expect** y **Pop.growth**, mientras que **Inflation** y **Unemployment** aparecen con pesos negativos. Por lo tanto, con la orientación elegida, **PC1 puede interpretarse como un eje de desarrollo y estabilidad socioeconómica**.

Gráficamente, esta interpretación se observa en el plano PC1-PC2: países como **Luxemburgo**, **Suiza** y **Noruega** aparecen hacia el lado positivo de PC1, mientras que países como **Ucrania**, **Bulgaria**, **Estonia** o **Letonia** aparecen hacia el lado negativo.

En síntesis, PC1 resume una oposición entre países con mejores indicadores económicos y sociales frente a países con mayores señales de inestabilidad macroeconómica o laboral.